# Ateliers pratiques Big Data sous HDP

# Prof. Karim Baïna

karim.baina@gmail.com

Expert Big Data Engineering & Analytics

# Atelier 6: Utiliser Apache Hive pour accéder aux données Hadoop

But : Cet exercice vous présente Apache Hive. Vous allez acquérir de l'expérience avec le shell Hive CLI pour stocker, traiter et accéder aux données Hadoop. Vous apprendrez également à obtenir des informations sur la configuration Hive à l'aide de l'interface utilisateur Web Ambari.

L'entrepôt de données Apache Hive facilite l'interrogation et la gestion de grands ensembles de données qui résident dans le stockage distribué. Construit sur Apache Hadoop, il fournit :

- Outils permettant d'extraire/transformer/charger facilement les données (ETL).
- Un mécanisme pour imposer une structure sur divers formats de données.
- Accès aux fichiers stockés directement dans Apache HDFS ou dans d'autres systèmes de stockage de données tels que Apache HBase.
- Exécution de requêtes via MapReduce.

Hive définit un langage de requête simple de type SQL, appelé HiveQL, qui permet aux utilisateurs familiarisés avec SQL d'interroger les données. Dans le même temps, ce langage permet également aux programmeurs familiarisés avec le framework MapReduce de brancher leurs mappeurs et réducteurs personnalisés pour effectuer des analyses plus sophistiquées qui pourraient ne pas être prises en charge par les capacités intégrées du langage. QL peut également être étendu avec des fonctions scalaires personnalisées définies par l'utilisateur (UDF), des agrégations (UDAF) et des fonctions de table (UDTF).

Hive n'exige pas que les données lues ou écrites soient au "format Hive", il n'y a rien de tel. Hive fonctionne aussi bien sur Thrift, control délimité ou vos formats de données spécialisés.

Hive n'est pas conçu pour les charges de travail OLTP et n'offre pas de requêtes en temps réel ni de mises à jour au niveau des lignes. Il est préférable de l'utiliser pour les tâches par lots sur de grands ensembles de données d'ajout uniquement (comme les journaux Web). Les valeurs Hive les plus importantes sont l'évolutivité (évolutivité avec plus de machines ajoutées dynamiquement au cluster Hadoop), l'extensibilité (avec le framework MapReduce et UDF/UDAF/UDTF), la tolérance aux pannes et le couplage lâche avec ses formats d'entrée. En bref, considérez Hive comme une base de données SQL à ajout uniquement. Hive est utile pour l'intégration SQL si vous souhaitez stocker des données à long terme à traiter, à résumer et à recharger. La principale limitation de Hive est la vitesse des requêtes. Lorsqu'il s'agit de milliards de lignes, il n'y a pas d'interrogation en direct des données qui serait suffisamment rapide pour une interface interactive avec les données. Par exemple, avec l'enregistrement des données, les quantités de données peuvent être énormes, mais ce dont vous avez souvent besoin, c'est d'une requête rapide et flexible sur des données résumées ou extrêmes, c'est-à-dire des défauts et des échecs.

Dans cet exercice, vous allez apprendre à obtenir des informations sur les services Hive à l'aide de l'interface utilisateur Web Ambari. Vous utiliserez également la CLI Hive pour créer des tables Hive, importer des données dans Hive et interroger des données Hive. Enfin, vous utilisez la CLI Beeline pour interroger des données dans Hive.

# Tâche 1. Apprendre à gérer des données Hadoop à travers des tables Hive managées relationnelles

Vous êtes déjà connecté entant que student sur votre VM HDP.

NB. Si le fichier CDR.csv est déjà mis sur HDFS /user/student/data sauter-les étapes 1-4 !!

1. Uploader un fichier de données CDR depuis votre machine vers le compte student de la machine virtuelle

(Sous Windows) Clicker sur le menu **Démarrer**, puis rechercher **cmd**.

Mettez-vous sur le répertoire contenant le fichier de données CDR.csv (par ex. C:)

Taper par exemple:

scp -r -p -P 2222 CDR.csv student@192.168.50.129:CDR.csv

NB. Dans la figure suivante, Remplacez 192.168.50.129 par l'URL (ou l'adresse IP) de votre VM HDP!!

```
I:\DATALAKE\20210105\async-ensias\async-Teaching\Big_Data_AMOA\Demos\R&D\CDRGenerator>scp -r -p -P 2222 CDR.csv student@192.168.50.129:CDR.csv student@192.168.50.129's password:

CDR.csv 100% 128MB 94.8MB/s 00:01
```

### 2. S'assurer du bon transfert du fichier de données depuis votre machine au compte de l'utilisateur (student) dans la VM

Retourner à votre console de la VM HDP et Taper :

[student@sandbox-hdp ~]\$ ls CDR.csv [student@sandbox-hdp ~]\$ ■

# 3. Uploader ce fichier de données depuis Linux de la VM vers l'espace HDFS associé à l'utilisateur (student)

Sur votre console de la VM HDP, Taper :

### Besoin de création du répertoire data/cdr

hadoop fs -mkdir /user/student/data/cdr

hadoop fs -put /home/student/CDR.csv /user/student/data/cdr/

### 4. Afficher les informations à propos du fichier de données HDFS

hadoop fs -ls data/cdr/CDR.csv

(oubien hadoop fs -ls /user/student/data/cdr/CDR.csv vu que /user/student/ est par défaut)

```
[student@sandbox-hdp ~]$ hadoop fs -ls data/cdr/CDR.csv -rw-r--r- 1 student student 132428102 2021-09-28 22:05 data/cdr/CDR.csv
```

#### 5. Exploration des données du fichier HDFS CDR.csv

hadoop fs -cat /user/student/data/cdr/CDR.csv | head -n 10

```
[student@sandbox-hdp ~]$ hadoop fs -cat /user/student/data/cdr/CDR.csv | head -n 10 c1070550-08d7-42bf-84b2-9f67ce9aldfa | 0609176182 | 0684508434 | 2021-09-13 | 15:14:57.041 | 2021-09-13 | 15:14:57.041 | SMS | 0.8072003 | ANSWERED 50def1fde-ae78-4902-a5ac-54cd790d5bcb | 0629728131 | 0616679734 | 2021-09-19 | 14:23:32.791 | 2021-09-19 | 14:26:06.988 | VOICE | 0.8080974 | ANSWERED 67be98b-90f7-43f3-a878-efe4d6fbfcb5 | 0679914600 | 0691495655 | 2021-10-14 | 18:02:38.434 | 2021-10-14 | 18:04:49.222 | VOICE | 0.013672888 | ANSWERED b741c7d6-9d23-47f1-bea1-f2788d65faf4 | 0612353921 | 0625883917 | 2021-09-18 | 16:17:40.110 | 2021-09-18 | 16:17:40.110 | SMS | 0.30302763 | ANSWERED 6038f390-90df-418c-995a-e95ebf42df54 | 0640784239 | 0676557336 | 2021-09-22 | 00:44:44.629 | 2021-09-22 | 00:47:10.159 | VOICE | 0.07670128 | ANSWERED dcd1751c-4358-4354-aaa0-c630438da009 | 0611901116 | 06906479453 | 2021-10-01 | 10:17:47.399 | 2021-10-01 | 10:19:56.727 | VOICE | 0.07953727 | ANSWERED 6038425d-9e9b-41e2-8436-dfdbaf33907a | 0631374947 | 0600587955 | 2021-09-30 | 16:54:46.061 | 2021-09-30 | 16:57:19.763 | VOICE | 0.73849326 | ANSWERED 5985d6ca-969f-4ce2-9e77-a530d1a1b418 | 0696524704 | 0623395634 | 2021-09-07 | 20:12:53.066 | 2021-09-07 | 20:15:01.913 | VOICE | 0.6276111 | ANSWERED 095ebfb5-f6fb-4992-99f1-0714664641d4 | 0618422948 | 0664041874 | 2021-09-04 | 01:42:31.907 | 2021-10-04 | 00:09:00.737 | SMS | 0.756527 | ANSWERED 1793a21b-127a-4950-9fe1-c77f014d3726 | 0657102291 | 0663944393 | 2021-10-04 | 00:09:00.737 | 2021-10-04 | 00:09:00.737 | SMS | 0.756527 | ANSWERED 1793a21b-127a-4950-9fe1-c77f014d3726 | 0657102291 | 0663944393 | 2021-10-04 | 00:09:00.737 | 2021-10-04 | 00:09:00.737 | SMS | 0.756527 | ANSWERED 1793a21b-127a-4950-9fe1-c77f014d3726 | 0657102291 | 0663944393 | 2021-10-04 | 00:09:00.737 | 2021-10-04 | 00:09:00.737 | SMS | 0.756527 | ANSWERED 1793a21b-127a-4950-9fe1-c77f014d3726 | 0657102291 | 0663944393 | 2021-10-04 | 00:09:00.737 | 2021-10-04 | 00:09:00.737 | SMS | 0.756527 | ANSWERED 1793a21b-127a-4950-9fe1-
```

- 1. id: STRING
- 2. calling\_num : STRING (numéro appelant)
- 3. called num: STRING (numéro appelé)
- 4. start\_time : TIMESTAMP (début appel)
- 5. end\_time : TIMESTAMP (fin appel)
- 6. call\_type : STRING (Voice, SMS)
- 7. charge : FLOAT (coût de l'appel chargé à l'appelant)
- 8. call\_result : STRING (ANSWERED, BUSY) (statut de l'appel)

Source du dataset : génération aléatoire automatique.

### 6. Assurez-vous que tous les services Hadoop sont démarrés à travers Ambari Web UI



### 7. Lancer le shell Hive CLI de datawarehouse Hive

#### /usr/bin/hive shell

```
[student@sandbox-hdp ~]$ /usr/bin/hive shell
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/usr/hdp/3.0.1.0-187/hive/lib/log4j-slf4j-impl-2.10.0.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/usr/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/
```

### 8. Créer une base de données pour le compte courant (student)

### CREATE DATABASE db student;

```
0: jdbc:hive2://sandbox-hdp.hortonworks.com:2> CREATE DATABASE db_student;
INFO : Compiling command(queryId=hive_20210929094908_3bf20a38-5dfe-47fb-8b1d-d9db3e1c1012): CREATE DATABASE db_student
INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchemas:null, properties:null)
INFO : Completed compiling command(queryId=hive_20210929094908_3bf20a38-5dfe-47fb-8b1d-d9db3e1c1012); Time taken: 0.085 seconds
INFO : Executing command(queryId=hive_20210929094908_3bf20a38-5dfe-47fb-8b1d-d9db3e1c1012): CREATE DATABASE db_student
INFO : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=hive_20210929094908_3bf20a38-5dfe-47fb-8b1d-d9db3e1c1012); Time taken: 0.58 seconds
INFO : OK
No rows affected (0.851 seconds)
0: jdbc:hive2://sandbox-hdp.hortonworks.com:2>
```

### 9. Vérifier la création de la base de données du compte courant (student)

### SHOW DATABASES;

```
0: jdbc:hive2://sandbox-hdp.hortonworks.com:2> SHOW DATABASES;
INFO : Compiling command(queryId=hive_20210929095059_465efcb0-cc0d-4bf7-a754-7e08d6be9ca4): SHOW DATABASES
INFO : Semantic Analysis Completed (retrial = false)
INFO : Semantic Analysis Completed (retrial = false)
INFO : Semantic Analysis Completed (retrial = false)
INFO : Completed compiling command(queryId=hive_20210929095059_465efcb0-cc0d-4bf7-a754-7e08d6be9ca4); Time taken: 0.017 seconds
INFO : Completed compiling command(queryId=hive_20210929095059_465efcb0-cc0d-4bf7-a754-7e08d6be9ca4); SHOW DATABASES
INFO : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=hive_20210929095059_465efcb0-cc0d-4bf7-a754-7e08d6be9ca4); Time taken: 0.005 seconds
INFO : OK

| database_name |
| db student |
| default |
| default |
| information_schema |
| sys |
| 5 rows selected (0.222 seconds)
| 0: jdbc:hive2://sandbox-hdp.hortonworks.com:2> |
```

### 10. Vérifier la création de la base de données du compte courant (student)

### use db student;

```
0: jdbc:hive2://sandbox-hdp.hortonworks.com:2> use db_student ;
INFO : Compiling command(queryId=hive_20210929095231_9119d209-1801-4c9d-a192-08f086f8b607): use db_student
INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchemas:null, properties:null)
INFO : Completed compiling command(queryId=hive_20210929095231_9119d209-1801-4c9d-a192-08f086f8b607); Time taken: 0.026 seconds
INFO : Executing command(queryId=hive_20210929095231_9119d209-1801-4c9d-a192-08f086f8b607): use db_student
INFO : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=hive_20210929095231_9119d209-1801-4c9d-a192-08f086f8b607); Time taken: 0.015 seconds
INFO : OK
No rows affected (0.053 seconds)
0: jdbc:hive2://sandbox-hdp.hortonworks.com:2> ■
```

### 11. Créer une table Hive CDR

```
CREATE TABLE CDR (
id STRING,
calling_num STRING,
called_num STRING,
start_time TIMESTAMP,
end_time TIMESTAMP,
call_type STRING,
charge FLOAT,
call_result STRING) row format delimited
fields terminated by '|'
lines terminated by '\n'
stored as textfile;
```

### 12. Vérifier la création de la table Hive CDR dans la base de données Hive associée à l'utrilisateur courant (student)

use db\_student; show tables;

### 13. Vérifier le schéma de la table CDR dans Hive

### describe cdr;

```
0: jdbc:h1ve2://sandbox-hdp.hortonworks.com:2> describe cdr;
INFO : Compiling command(queryId=hive 20210926135822 8893d7f7-e044-4cdl-b8bb-3cc621dc6be0): describe cdr
INFO : Senantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchemas:[FieldSchema(name:col name, type:string, comment:from deserializer), FieldSchema(name:data_type, type:string, comment:fro
```

### 14. Charger le fichier de données CDR.csv depuis HDFS vers la table Hive CDR

LOAD DATA INPATH '/user/student/data/cdr/CDR.csv' OVERWRITE INTO TABLE cdr;

```
0: jdbc:hive2://sandbox-hdp.hortonworks.com:2> LOAD DATA LOCAL INPATH '/home/student/cdr/CDR.csv' OVERWRITE INTO TABLE CDR;
INFO : Compiling command(queryId=hive_20210926134033_a78dada8-759f-41d3-9b58-f4e6alcc4597): LOAD DATA LOCAL INPATH '/home/student/CDR.csv' OVERWRITE INTO TABLE CDR;
INFO : Semantic Analysis Completed (retrial = false)
INFO : Completed compiling command(queryId=hive_20210926134033_a78dada8-759f-41d3-9b58-f4e6alcc4597); Time taken: 0.256 seconds
INFO : Executing command(queryId=hive_20210926134033_a78dada8-759f-41d3-9b58-f4e6alcc4597): LOAD DATA LOCAL INPATH '/home/student/CDR.csv' OVERWRITE INTO TABLE CDR
INFO : Starting taks [Stage-16] MOVE] in serial mode
INFO : Completed executing command(queryId=hive_20210926134033_a78dada8-759f-41d3-9b58-f4e6alcc4597); Time taken: 2.895 seconds
INFO : Completed executing command(queryId=hive_20210926134033_a78dada8-759f-41d3-9b58-f4e6alcc4597); Time taken: 2.895 seconds
INFO : Completed executing command(queryId=hive_20210926134033_a78dada8-759f-41d3-9b58-f4e6alcc4597); Time taken: 2.895 seconds
INFO : Osmpleted executing command(queryId=hive_20210926134033_a78dada8-759f-41d3-9b58-f4e6alcc4597); Time taken: 2.895 seconds
INFO : Osmpleted executing command(queryId=hive_20210926134033_a78dada8-759f-41d3-9b58-f4e6alcc4597); Time taken: 2.895 seconds
INFO : Osmpleted executing command(queryId=hive_20210926134033_a78dada8-759f-41d3-9b58-f4e6alcc4597); Time taken: 2.895 seconds
INFO : Osmpleted executing command(queryId=hive_20210926134033_a78dada8-759f-41d3-9b58-f4e6alcc4597); Time taken: 2.895 seconds
INFO : Osmpleted executing command(queryId=hive_20210926134033_a78dada8-759f-41d3-9b58-f4e6alcc4597); Time taken: 2.895 seconds
```

### 15. Vérifier le chargement du fichier de données CDR.csv depuis HDFS vers la table Hive CDR

### select \* from cdr LIMIT 10;

```
INFO : Compiling command(queryId=hive_20210926141730_5c5c544c-7490-412e-84c3-73960049a8f4): select * from CDR LIMIT 10
INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema (fieldSchemas:[FieldSchema(name:cdr.id, type:string, comment:null), FieldSchema(name:cdr.calling_num, type:string, comment:null), FieldSchema(name:cdr.calling_num,
```

NB. Sous les versions (2.6/2.7 sous Azure), la requête affichera les données sans les noms des colonnes.

### 16. Exploration de la force de SQL sur les données réparties sous HDFS de la table Hive CDR

select CALLING\_NUM, (END\_TIME-START\_TIME) AS DURATION from CDR ORDER BY DURATION DESC LIMIT 10;

+	+
calling_num	duration
0664625205   0643567331   0695884845   0620971959   0668758824   0656468109   0613677842   0634486253   0647313423   0677003366	0 00:03:00.000000000   0 00:03:00.000000000   0 00:03:00.000000000   0 00:03:00.000000000   0 00:03:00.000000000   0 00:03:00.000000000   0 00:03:00.000000000   0 00:03:00.000000000   0 00:03:00.000000000   0 00:03:00.000000000

10 rows selected (10.437 seconds)

select Date(START\_TIME) AS CALL\_DATE, Count(\*) AS CALLS

from CDR
where CALL\_TYPE = "VOICE"
GROUP BY Date(START\_TIME)
ORDER BY CALLS DESC
LIMIT 10;

call_date	calls
2021-10-18   2021-09-21   2021-09-11   2021-09-09   2021-10-15   2021-10-07   2021-09-18   2021-10-11   2021-09-15   2021-09-05	10250   10247   10237   10226   10223   10206   10195   10193   10192   10177
+	++

10 rows selected (13.246 seconds)

```
select MONTH(START TIME) AS CALL MONTH, YEAR(START TIME) AS CALL YEAR, Count(*) AS
CALLS
from CDR
where CALL_TYPE = "VOICE"
GROUP BY MONTH(START_TIME), YEAR(START_TIME)
ORDER BY CALLS DESC
LIMIT 1;
                          | call_month | call_year | calls |
                          +-----
                             | 2021 | 294148 |
                          | 9
                          +----+
                          1 row selected (10.576 seconds)
select YEAR(START_TIME), AVG(DATEDIFF(END_TIME,START_TIME)) AS CALL_DURATION_AVG
from CDR
where CALL TYPE = "VOICE"
                                                 | sms_date | sms
GROUP BY YEAR(START TIME);
                                                 +-----
                                                 | 2021-09-20 | 10274
                                                 2021-09-30 | 10204
select Date(START TIME) AS SMS DATE, Count(*) AS SMS
                                                 2021-09-17 | 10195
from CDR
                                                  2021-09-29 | 10185
where CALL_TYPE = "SMS"
                                                 | 2021-10-02 | 10170
GROUP BY Date(START_TIME)
                                                 | 2021-10-01 | 10160
ORDER BY SMS DESC
                                                 | 2021-09-03 | 10141
LIMIT 10;
                                                 | 2021-10-05 | 10140
| 2021-10-09 | 10134
| 2021-10-08 | 10132
                                                 10 rows selected (11.484 seconds)
SELECT NUMBER, SUM(DEGREE PLUS) DP, SUM(DEGREE MOINS) DM, SUM(DEGREE PLUS) +
SUM(DEGREE_MOINS) DEGREE
FROM
(select CALLING NUM NUMBER, count(CALLED NUM) DEGREE PLUS, 0 DEGREE MOINS
from CDR
GROUP BY CALLING NUM
HAVING count(CALLED NUM) != 0)
UNION
(select CALLED NUM NUMBER, 0 DEGREE PLUS, count(CALLING NUM) DEGREE MOINS
from CDR
GROUP BY CALLED NUM
HAVING count(CALLING NUM) !=0)
                                    | number | dp | dm | degree |
                                    | 0649349936 | 1 | 3 | 4
GROUP BY NUMBER
                                    0649402765
                                                    | 3
                                                          4
ORDER BY DEGREE DESC, NUMBER ASC
                                     0600021946
                                                    | 1
                                                         1 3
                                                    0
LIMIT 10;
                                     0600606028
                                               | 3
                                                          3
                                     0601243493
                                               | 1
                                                          3
                                                         | 3
                                     0601871839
                                     0601945203
                                               1
                                                    2
                                                          3
                                    0602189738 | 2
                                    0606468972 3
0607708592 1
                                                    0
```

### 17. Quitter le shell Hive CLI

į 2

0: jdbc:hive2://sandbox-hdp.hortonworks.com:2>

10 rows selected (21.996 seconds)

# Tâche 2. Apprendre à gérer des données Hadoop à travers des tables Hive non managées (externes)

**Pré-requis : Atelier 5 :** Développer et Exécuter une Application Spark en Python – **Tâche 3.** Apprendre à créer et exécuter une application Spark en Python.

En Atelier 5 (Tâche 3), la programmation Spark vous a permis de faire le pré-traitement des données SMS brutes, et en Atelier 6 (Tâche 2), le requêtage Hive vous permettra de faire de l'analyse sur les données pré-traitées.

### 1. Se logguer entant qu'utilisateur hdfs

su su - hdfs

### 2. Donner les privilèges sur le répertoire de données à l'utilisateur hive du groupe hdfs

hadoop fs -chown -R hive:hdfs /user/student/output-spamsms/

### 3. quitter la session hdfs

exit

### 4. quitter la session root

exit

### 5. Lancer le shell Hive CLI de datawarehouse Hive

/usr/bin/hive shell

# 6. Créer une table externe Hive pointant sur les données HDFS (de comptage de mot des sms) non managées par Hive

```
CREATE EXTERNAL TABLE IF NOT EXISTS db_student.SMSWordCount (word STRING, countinspam INT, countinham INT) ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
```

LINES TERMINATED BY '\n'

STORED AS TEXTFILE

LOCATION '/user/student/output-spamsms';

FROM db\_student.SMSWordCount SELECT word, countinspam, countinham WHERE word ='money';

word	countinspam	countinham
money	3	
4.	4.	4

FROM db\_student.SMSWordCount SELECT word, countinspam, countinham WHERE word ='work';

word	countinspam	countinham	
work		56	

FROM db\_student.SMSWordCount SELECT word, countinspam, countinham WHERE word ='dating'; FROM db\_student.SMSWordCount SELECT word, countinspam, countinham WHERE word ='chat';

word	-+   countinspam	countinham
dating	•	NULL
	· 	
	countinspam	
chat	37	11
	+	

# Tâche 3. Apprendre à gérer des données Hadoop à travers des tables Hive managées multidimensionnelles

NB. Si le fichier city.csv est déjà mis sur HDFS /user/student/data/cities sauter-les étapes 1-5 !!

1. Uploader un fichier de données city.csv depuis votre machine vers le compte student de la machine virtuelle

(Sous Windows) Clicker sur le menu **Démarrer**, puis rechercher **cmd**. Mettez-vous sur le répertoire contenant le fichier de données city.csv (par ex. l:)

Taper par exemple:

scp -P 2222 city.csv student@kbaina.westeurope.cloudapp.azure.com:city.csv

NB. Dans la figure suivante, Remplacez kbaina.westeurope.cloudapp.azure.com par l'URL (ou l'adresse IP) de votre VM HDP !!

### 2. S'assurer du bon transfert du fichier de données depuis votre machine au compte de l'utilisateur (student) dans la VM

Retourner à votre console de la VM HDP

exemple: ssh student@192.168.50.128 -p 2222

et Taper:

ls

### NB. Dans la figure suivante, Remplacez 192.168.50.128 par l'URL (ou l'adresse IP) de votre VM HDP!!

```
Microsoft Windows [version 10.0.19042.1348]
(c) Microsoft Corporation. Tous droits réservés.
C:\Users\workstation>ssh student@192.168.50.128 -p 2222
student@192.168.50.128's password:
Last login: Mon Nov 29 00:06:36 2021
[student@sandbox-hdp ~]$ ls
                              ChurnerCountByGenderReducer.py CustomerCountByGenderReducer.py spam-sms.csv
CDR.csv
                                                               Customer.csv
CDR.java
                              city.csv
                                                                                                spam-sms.py
                              CustomerCountByGenderMapper.py DE0121.signe.pdf
                                                                                                tweets.json
[student@sandbox-hdp ~1$
```

# 3. Uploader ce fichier de données depuis Linux de la VM vers l'espace HDFS associé à l'utilisateur (student)

Sur votre console de la VM HDP, Taper :

#### Besoin de création du répertoire data/cities

hadoop fs -mkdir /user/student/data/cities/

hadoop fs -put '/home/student/city.csv' /user/student/data/cities/

### 4. Afficher les informations à propos du fichier de données HDFS

hadoop fs -ls data/cities/city.csv

(oubien hadoop fs -ls /user/student/data/cities/city.csv vu que /user/student/ est par défaut)

### 5. Exploration des données du fichier HDFS city.csv

hadoop fs -cat /user/student/data/cities/city.csv | head -n 10

```
[student@sandbox-hdp:~]$ hadoop fs -cat /user/student/data/cities/city.csv | head -n 10
ad,aixas,Aixs,06,,42.4833333,1.4666667
ad,aixirivali,Aixirivali,06,,42.4666667,1.5
ad,aixirivall,Aixirivall,06,,42.4666667,1.5
ad,aixirvall,Aixirivall,06,,42.4666667,1.5
ad,aixovall,Aixirvall,06,,42.4666667,1.8
ad,aixovall,Aixovall,06,,42.4666667,1.8
ad,aixovall,Aixovall,06,,42.4666667,1.8
ad,aixovall,Aixovall,06,,42.4666667
ad,andorra,Andorra,07,,42.5,1.5166667
ad,andorra la vella,Andorra la Vella,07,20430,42.5,1.5166667
ad,andorre,Andorre,07,,42.5,1.5166667
ad,andorre,Andorre,07,,42.5,1.5166667
ad,andorre-la-vieille,Andorre-la-Vieille,07,,42.5,1.5166667
cat: Unable to write to output stream.
[student@sandbox-hdp ~]$
```

- Country\_Code : STRING (Code du pays)
- Name : STRING (Nom de la ville)
- AccentCity : STRING (Nom de la ville avec accents éventuels)
- Region : STRIN (région à laquelle apparient la ville)
- Population : INT (nombre d'habitants)
- Latitude : FLOAT (lattitude)Longitude : FLOAT (longitude)

Source du dataset : Open data de : https://www.maxmind.com

### 6. Se logguer entant qu'utilisateur hdfs

su su - hdfs

### 7. Donner les privilèges sur le répertoire de données à l'utilisateur hive du groupe hdfs

hadoop fs -chown -R hive:hdfs /user/student/cities/

### 8. quitter la session hdfs

exit

### 9. quitter la session root

exit

```
Sélection student@sandbox-hdp:~

C:\Users\workstation>ssh student@192.168.50.128 -p 2222

student@192.168.50.128's password:

Last login: Wed Dec 1 01:21:42 2021 from 172.18.0.3

[student@sandbox-hdp ~]$ su -

Password:

Last login: Wed Dec 1 01:21:51 UTC 2021 on pts/0

[root@sandbox-hdp ~]# su - hdfs

Last login: Wed Dec 1 01:21:56 UTC 2021 on pts/0

[hdfs@sandbox-hdp ~]$ hadoop fs -chown -R hive:hdfs /user/student/data/cities/
[hdfs@sandbox-hdp ~]$ exit

logout

[root@sandbox-hdp ~]# exit
```

### NB. Dans la figure précédente, Remplacez 192.168.50.128 par l'URL (ou l'adresse IP) de votre VM HDP!!

### 6. Lancer le shell Hive CLI de datawarehouse Hive

/usr/bin/hive shell

```
[student@sandbox-hdp ~]$ /usr/bin/hive shell
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/usr/hdp/3.0.1.0-187/hive/lib/log4j-slf4j-impl-2.10.0.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/usr/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/
```

### 7. Se Positionner sur la base de données du compte courant (student)

### use db student;

```
0: jdbc:hive2://sandbox-hdp.hortonworks.com:2> use db_student;
INFO : Compiling command(queryId=hive_20210929095231_9119d209-1801-4c9d-a192-08f086f8b607): use db_student
INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchemas:null, properties:null)
INFO : Completed compiling command(queryId=hive_20210929095231_9119d209-1801-4c9d-a192-08f086f8b607); Time taken: 0.026 seconds
INFO : Executing command(queryId=hive_20210929095231_9119d209-1801-4c9d-a192-08f086f8b607): use db_student
INFO : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=hive_20210929095231_9119d209-1801-4c9d-a192-08f086f8b607); Time taken: 0.015 seconds
INFO : OK
No rows affected (0.053 seconds)
0: jdbc:hive2://sandbox-hdp.hortonworks.com:2>
```

### 7. Créer une table Externe (non managée) Hive EXTERNAL\_CITY

CREATE EXTERNAL TABLE IF NOT EXISTS db\_student.EXTERNAL\_CITY(Country\_Code STRING, Name STRING, AccentCity STRING, Region STRING, Population INT, Latitude FLOAT, Longitude FLOAT) ROW FORMAT DELIMITED FIELDS TERMINATED BY ',' LINES TERMINATED BY '\n' STORED AS TEXTFILE LOCATION '/user/student/data/cities/';

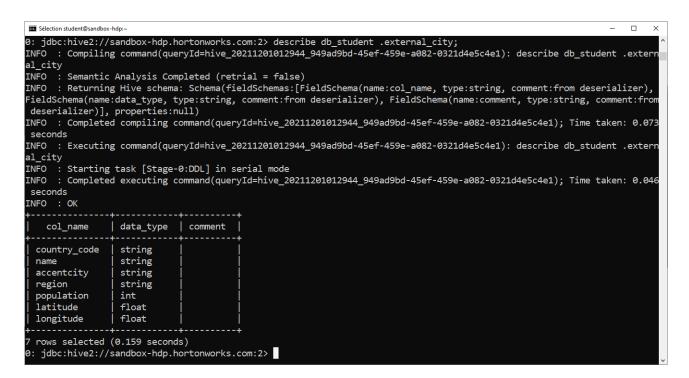
# 8. Vérifier la création de la table Hive CDR dans la base de données Hive associée à l'utrilisateur courant (student)

show tables;

```
0: jdbc:hive2://sandbox-hdp.hortonworks.com:2> show tables;
INFO : Compiling command(queryId=hive_20211201012823_62bafb7c-fff6-44af-8fee-e9a8160835b0): show tables INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchemas:[FieldSchema(name:tab_name, type:string, comment:from deserializer)]
properties:null)
INFO : Completed compiling command(queryId=hive_20211201012823_62bafb7c-fff6-44af-8fee-e9a8160835b0); Time taken: 0.028
seconds
INFO : Executing command(queryId=hive_20211201012823_62bafb7c-fff6-44af-8fee-e9a8160835b0): show tables
      : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=hive_20211201012823_62bafb7c-fff6-44af-8fee-e9a8160835b0); Time taken: 0.012
 seconds
INFO : OK
     tab_name
  cdr
  customer
  employee
  external_city
  smswordcount
5 rows selected (0.238 seconds)
 : jdbc:hive2://sandbox-hdp.hortonworks.com:2>
```

### 9. Vérifier le schéma de la table external\_city dans Hive

describe db student.external city;



### 10. Explorer les données de la table external city à travers quelques requêtes Hive

SELECT Country\_Code, sum(Population) FROM db\_student.external\_city WHERE Country\_Code='br' GROUP BY Country\_Code;

```
student@sandbox-hdp:
      : TaskCounter_Reducer_2_OUTPUT_out_Reducer_2:
INFO
           OUTPUT RECORDS: 0
     : org.apache.hadoop.hive.ql.exec.tez.HiveInputCounters:
INFO
           GROUPED_INPUT_SPLITS_Map_1: 3
INPUT_DIRECTORIES_Map_1: 1
INFO
INFO
           INPUT_FILES_Map_1: 1
RAW_INPUT_SPLITS_Map_1: 3
INFO :
INFO
INFO : Completed executing command(queryId=hive_20211201013416_5a43f79d-ef8b-441e-9838-336b768f3fc4); Time taken: 27.07
7 seconds
INFO : OK
 country_code
                 133449921
1 row selected (31.749 seconds)
3: jdbc:hive2://sandbox-hdp.hortonworks.com:2>
```

SELECT Country\_Code, SUM(Population) AS somme FROM db\_student.external\_city GROUP BY Country\_Code HAVING somme >= 100000000 ORDER BY somme DESC;

```
student@sandbox-hdp:-
                                                                                                                    X
          RAW INPUT_SPLITS_Map_1: 3
INFO :
INFO : Completed executing command(queryId=hive_20211201013525_d3c7a71c-f398-4c9a-81e7-55ec00ab114a); Time taken: 14.07
2 seconds
INFO : OK
 country_code
                 somme
 in
                  259227307
                  218884084
                  179123400
 us
                  133449921
 br
                  109505345
 ru
                 101577008
 jр
5 rows selected (14.484 seconds)
3: jdbc:hive2://sandbox-hdp.hortonworks.com:2>
```

### 11. Créer une table partitionnée partitioned\_city dans Hive

CREATE TABLE IF NOT EXISTS

db\_student.PARTITIONED\_CITY(Name STRING, AccentCity STRING, Region STRING, Population INT,
Latitude FLOAT, Longitude FLOAT)
PARTITIONED BY (Country\_Code STRING)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY ','
LINES TERMINATED BY '\n'
STORED AS TEXTFILE;

11. Créer la partition statique (i.e. relative à une valeur donnée de la clé de partitionnement (Country\_Code STRING) – un pays donné) dans la table Hive PARTITIONED\_CITY et l'alimenter depuis la table externe Hive EXTERNAL\_CITY

INSERT INTO db\_student.PARTITIONED\_CITY
PARTITION (Country\_Code = 'ma')
SELECT Name, AccentCity, Region, Population, Latitude,
Longitude
FROM db\_student.EXTERNAL\_CITY
WHERE Country Code = 'ma';

select \* from db\_student.partitioned\_city where Name ='casablanca';

student@sandbox-hdp:~							- 🗆 ×
partitioned_ci	ty.name   partiti	+   partitioned_city.accen ned_city.country_code	tcity		partitioned_city.population	+    partitioned_city.latitude	+    partitioned_
casablanca		Casablanca		45	3609698	33.592777	-7.619157
1 row selected (	0.347 sec	onds) dp.hortonworks.com:2>	+	•	*	*	*

### 12. Quitter Hive CLI momentanément

!a

13. Explorer la structure de stockage HDFS réalisé par Hive pour la table partitionnée partitioned city

hadoop fs -ls /warehouse/tablespace/managed/hive/db\_student.db/partitioned\_city

NB. Sous les versions (2.6/2.7 sous Azure), tapez : hadoop fs -ls /apps/hive/warehouse/db\_student.db/partitioned\_city

Remarque : Particularité des tables partitionnées. Différemment des tables normales stockées sous HDFS comme des buckets plats dans une sous répertoire portant le même nom de la table sous /warehouse/tablespace/managed/hive/, pour la table managée partitionnée db\_student.db/partitioned\_city, Hive crée une arborescence des niveaux multi-dimensionnel imbriqués de répertoire **HDFS** (ici une seule dimension/niveau le Country Code) /warehouse/tablespace/managed/hive/ pour les clefs de partitions (entant q'un pur Big data datawarehouse).

NB. Sous les versions (2.6/2.7 sous Azure), les données partitionnées sont sur /apps/hive/warehouse/db\_student.db/partitioned\_city.

### 14. Revenir sur le shell Hive CLI de datawarehouse Hive

### /usr/bin/hive shell

```
[student@sandbox-hdp ~]$ /usr/bin/hive shell
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/usr/hdp/3.0.1.0-187/hive/lib/log4j-slf4j-impl-2.10.0.jar!/org/slf4j/impl/StaticLoggerBinder.class]
SLF4J: Found binding in [jar:file:/usr/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/hdp/3.0.1.0-187/
```

15. Créer deux nouvelles partitions statiques (i.e. relative à des valeurs données de la clé de partitionnement (Country\_Code STRING) – des pays donné) dans la table Hive PARTITIONED\_CITY et les alimenter depuis la table externe Hive EXTERNAL CITY

```
INSERT INTO db_student.PARTITIONED_CITY
PARTITION (Country_Code = 'fr')
SELECT Name, AccentCity, Region, Population, Latitude,
Longitude
FROM db_student.EXTERNAL_CITY
WHERE Country Code = 'fr';
```

```
INSERT INTO db_student.PARTITIONED_CITY
PARTITION (Country_Code = 'tn')
SELECT Name, AccentCity, Region, Population, Latitude,
Longitude
FROM db_student.EXTERNAL_CITY
WHERE Country_Code = 'tn';
```

16. Explorer plus en profondeur la structure et le contenu du stockage réalisé par Hive pour la table partitionnée partitinnée partitionnée partitionnée partitionnée partitionnée partitin

hadoop fs -ls -R /warehouse/tablespace/managed/hive/db\_student.db/partitioned\_city/country\_code\=tn/

NB. Sous les versions (2.6/2.7 sous Azure), tapez : hadoop fs -ls /apps/hive/warehouse/db\_student.db/partitioned\_city/country\_code\=tn/

hadoop fs -cat /warehouse/tablespace/managed/hive/db\_student.db/partitioned\_city/country\_code\=tn/delta 0000003 00000003 0000/000000 0 | head -n 10

NB. Sous les versions (2.6/2.7 sous Azure), tapez :

hadoop fs -cat /app/shive/warehouse/db\_student.db/partitioned\_city/country\_code\=tn/...... | head -n 10 Le nom du bucket dépendera ainsi de votre exécution du partitionnement statique.

NB. Dans la commande précédente Mettre les bons sous répertoires de la partition choisie !

```
[student@sandbox-hdp~]$ hadoop fs -cat /warehouse/tablespace/managed/hive/db_student.db/partitioned_city/country_code\=^tn/delta_0000003_0000003_000000000_0 | head -n 10
abarda,Abarda,28,\N,33.779213,10.768174
abbah qusur,Abbah Qusur,14,\N,35.94388,8.827776
`abbas,`Abbas,35,\N,33.896503,8.135551
abbes,Abbes,35,\N,33.896503,8.135551
abd er rahmane,Abd er Rahmane,23,\N,36.15,10.25
abd er rahmane el garsi zaouia,Abd er Rahmane el Garsi Zaoua,23,\N,36.15,10.25
abes,Abes,29,\N,33.88146,10.098196
abzeg,Abzeg,32,\N,35.028053,10.960506
ad dabdabah,Ad Dabdabah,29,\N,33.872475,9.797324
ad dakhilah,Ad Dakhilah,18,\N,36.86667,9.7
cat: Unable to write to output stream.
[student@sandbox-hdp ~]$
```

17. Créer des partitions dynamiques (i.e. relatives à toutes les valeurs de la clé de partitionnement (Country\_Code STRING) – des pays restant non encore créé) dans la table Hive PARTITIONED\_CITY et les alimenter depuis la table externe Hive EXTERNAL CITY

```
INSERT INTO db_student.PARTITIONED_CITY PARTITION (Country_Code) SELECT Name, AccentCity, Region, Population, Latitude, Longitude, Country_Code FROM db_student.EXTERNAL_CITY WHERE Country_Code not in('fr', 'ma', 'tn');
```

Créer des partitions dynamiques ressemble à invoquer une sorte d'itérateur!

NB. Sous les versions (2.6/2.7 sous Azure), il faudra forcer des variables de partitionnement dynamique :

```
SET hive.exec.dynamic.partition = true;
SET hive.exec.dynamic.partition.mode = nonstrict;
SET hive.exec.max.dynamic.partitions = 1000;
SET hive.exec.max.dynamic.partitions.pernode = 1000;
```

#les 4 propriétés peuvent être configurées également dans hive-site.xml

Puis refaire

INSERT INTO db\_student.PARTITIONED\_CITY PARTITION (Country\_Code) SELECT Name, AccentCity, Region, Population, Latitude, Longitude, Country\_Code FROM db\_student.EXTERNAL\_CITY WHERE Country\_Code not in('fr', 'ma', 'tn');

```
| State | Stat
```

Normalement, la commande devra réussir. Cependant, sous les versions (2.6/2.7 sous Azure), d'autres problèmes de réplications surgissent. Caused by: org.apache.hadoop.ipc.RemoteException(java.io.IOException): File /apps/hive/warehouse/db\_student.db/partitioned\_city/.hive-staging\_hive\_2021-12-02\_13-33-27\_937\_8827931192441516354-1/\_task\_tmp.-ex t-10000/country\_code=ca/\_tmp.000001\_3 could only be replicated to 0 nodes instead of minReplication (=1). There are 1 datanode(s) running and no node(s) are excluded in this operation.

### 18. Explorer les données de la table external\_city à travers quelques requêtes Hive

show partitions db\_student.partitioned\_city LIMIT 15;

### OK

- country\_code=ad
- country\_code=ae
- country\_code=af
- country code=ag
- country code=ai
- country code=al
- ...

```
Reindforderberby:

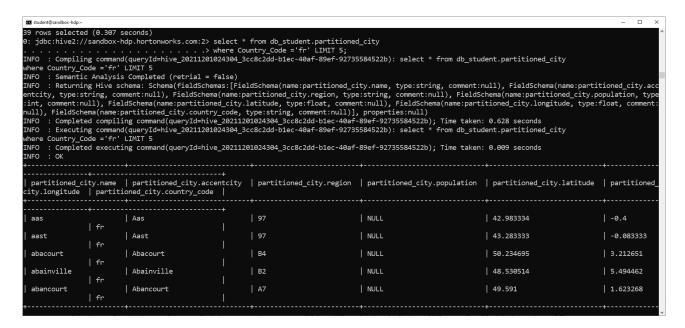
0: jdbc:hive2://sandbox-hdp.hortonworks.com:2> show partitions db_student.partitioned_city;
INFO : Compiling command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e): show partitions db_student.partitioned_city
INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchema:[fieldSchema(name:partition, type:string, comment:from deserializer)], properties:null)
INFO : Completed compiling command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e); Time taken: 0.197 seconds
INFO : Executing command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e); Time taken: 0.197 seconds
INFO : Completed executing command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e); Time taken: 0.054 seconds
INFO : Completed executing command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e); Time taken: 0.054 seconds
INFO : Completed executing command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e); Time taken: 0.054 seconds
INFO : Completed executing command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e); Time taken: 0.054 seconds
INFO : Completed executing command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e); Time taken: 0.054 seconds
INFO : Completed executing command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e); Time taken: 0.054 seconds
INFO : Completed executing command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e); Time taken: 0.054 seconds
INFO : Completed executing command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e); Time taken: 0.197 seconds
INFO : Completed executing command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e); Time taken: 0.197 seconds
INFO : Completed executing command(queryId=hive_20211201023919_993a3911-3780-4273-8bc8-cc5f6a4f173e); Time taken: 0.197 seconds
INFO : Completed executing command(queryId=hive_20211201023919_993a3911-3780-4273-8
```

# DESCRIBE FORMATTED db\_student.partitioned\_city PARTITION (country\_code='us');

```
П
      jdbc:hive2://sandbox-hdp.hortonworks.com:2> DESCRIBE FORMATTED db_student.partitioned_city
           JUNE 11 PARTITION COMMON RS. COMM. 22 DESARISE FORMATTED UI_SCUDENT.PARTITION (_COUNTRY_CODE='US');

Compiling command(queryId=hive_20211201024133_a53db0d6-aa79-48cf-8c0f-014c3f9f98c2): DESCRIBE FORMATTED db_student.partitioned_city
INFO : Compiling command(queryId=hive_20211201024133_a53db0d6-aa79-48cf-8c0f-014c3f9f98c2): DESCRIBE FORMATTED db_student.partitioned_city
PARTITION (country_code='us')
INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchemas:[FieldSchema(name:col_name, type:string, comment:from deserializer), FieldSchema(name:data_type, type:string, comment:from deserializer)], properties:null)
INFO : Completed compiling command(queryId=hive_20211201024133_a53db0d6-aa79-48cf-8c0f-014c3f9f98c2); Iner taken: 0.166 seconds
INFO : Executing command(queryId=hive_20211201024133_a53db0d6-aa79-48cf-8c0f-014c3f9f98c2): DESCRIBE FORMATTED db_student.partitioned_city
PARTITION (country_code='us')
INFO : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=hive_20211201024133_a53db0d6-aa79-48cf-8c0f-014c3f9f98c2); Time taken: 0.093 seconds
INFO : OK
    col_name
# col
                                                                                                                                                 data_type
                                                                                             data_type
string
string
                                                                                                                                                                                                                                    comment
    name accentcity
                                                                                              string
int
float
     region
     population
latitude
    longitude
                                                                                               float
                                                                                              NULL
NULL
                                                                                                                                                                                                                                    NULL
NULL
    # Partition Information
                                                                                              data_type
string
                                                                                                                                                                                                                                     comment
    country_code
                                                                                              NULL
                                                                                                                                                                                                                                     NULL
    # Detailed Partition Information
```

select \* from db\_student.partitioned\_city where Country\_Code ='fr' LIMIT 5;



select \* from db\_student.partitioned\_city where Country Code ='it' LIMIT 5;

here Country_Co NFO : Semantic NFO : Returnin ntcity, type:st int, comment:nu ull), FieldSche NFO : Complete NFO : Executin here Country_Co	de ='it' Analysi g Hive soring, con all), Fie ma(name: d compil g commande ='it'	LIMIT 5  s Completed (retrial = schema: Schema(fieldSchemmert:rull), FieldSchem (dSchemer) partition partition partitioned_city.countring command(queryId=hiv iqueryId=hiv iqueryId=hiv iqueryId=hiv iqueryId=hiv iqueryId=hiv 20211201:LIMIT 5	false) mas:[Fiel a(name:pa ed_city.l y_code, t e_2021120 024351_51	dSchema(name:partitioned_c: rtitioned_city.region, type atitude, type:float, commer ype:string, comment:null)] 1024351_51e199b7-0a59-4189- e199b7-0a59-4189-965a-523b	ity.name, type:string, comment:restring, comment:restring, comment:null), FieldSchema(name:parti, properties:null), properties:null), properties:null), profise-52369980fce6); Time taken:p980fce6): select * from db_stucture.pe65a-523b9980fce6); Time taken:	null), FieldSchema(name:partit chema(name:partitioned_city.pc itioned_city.longitude, type:f 0.243 seconds dent.partitioned_city	pulation, type
ity.longitude	partit	partitioned_city.acc   partitioned_city.code		partitioned_city.region	partitioned_city.population	partitioned_city.latitude	partitioned_
abadia a isola		Abadia a Isola		16	NULL	43.38333	11.2
abano		Abano		20	NULL	45.35	11.783333
abano terme	it	Abano Terme		20	19112	45.35	11.783333
abano terme	it	Abano Terme		20	19112	45.55	11.763333
abatemarco		Abatemarco		04	NULL	40.13333	15.35
abbadia	it	Abbadia		10	NULL	43.216667	13.4
	it	-+		+	-+	+	+
	4		+				

### 19. Quitter Hive CLI momentanément

!q

### 20. Explorer la structure de stockage HDFS réalisé par Hive pour la table partitionnée partitionned\_city

hadoop fs -ls /warehouse/tablespace/managed/hive/db\_student.db/partitioned\_city/ | head -n 15

**Question.** Que pensez-vous des trois styles de développement, test et déploiement de flux de données (dataflow) d'analyse de données Hadoop :

- Jobs Map Reduce (Programmation impérative du pattern MR sous Python et HadoopStreaming) en
   Atelier 4 ?
- Applications Spark (Programmation fonctionnelle du pattern MR, Spark SQL sous PySpark et sparksubmit) en Atelier 5 ?
- Requêtage Hive QL (sous Hive datawarehouse store) en Atelier 6 ? Bien qu'il n'y ait pas vraiment de comparaison objective entre un dataflow language (Python) sous deux moteurs d'exécution différentes (mapred avec une communication M&R on disk et spark avec une communication M&R in memory) et un data store non comparables du fait que chacun à son propre rôle et qu'ils se complètent vraiment ?

Résultats : Cet atelier vous a permis d'Obtenir des informations sur les services Hive à l'aide de l'interface utilisateur Web Ambari, d'Utiliser la CLI Hive pour créer des tables Hive, importer des données dans Hive et interroger des données sur Hive.